

MP1：参数平均的同预算实验

学号：3036797441。课程：DASE7506。日期：2026-09-28。所有实验均在本地从随机初始化开始；最终提交文件为 model-bundle.zip 中的 final.pt。

1. 任务、基线与研究问题

本作业研究下一 token 预测：给模型一段文字，让它预测紧接着出现的 token。token 是固定 BPE 分词器切出的文本单位，不一定是一个完整单词。输入 [A, B, C] 时，对应目标是 [B, C, D]；预测 C 时只能使用 A、B，不能提前看到答案。评分按独立的 256-token 因果窗口执行，不允许跨窗口保留状态。

固定基准为 WikiText-2，词表大小 2,048。评分指标 BPB 是每个原始 UTF-8 字节对应的平均负对数概率，越低越好。公式为 $BPB = \text{全部目标的负自然对数概率之和} / (\ln(2) \times \text{原文 UTF-8 字节数})$ 。字节数包括首 token 的字节；每个 split 除首 token 外的目标各评分一次。训练损失则是一个随机小批次上的交叉熵，不可直接与 BPB 相减。

原始模型为 4 层 GPT，宽度 128，4 个注意力头，共 1,088,256 个参数。它使用可学习 token 和位置向量、前置 LayerNorm、因果自注意力与前馈模块，并共享输入 embedding 和输出层权重。模型、配置、分词器、数据和固定评估器保留原样。本文的机制改动仅在训练期间另外维护一份指数移动平均 (EMA) 权重。

初始基线 B0 使用 seed 17、1,200 步、每步 32 条序列、每条 256 个目标，共 9,830,400 个训练目标。学习率、AdamW 和梯度裁剪均沿用 starter。初始基线验证 BPB 为 2.071087433，冻结后完整测试 BPB 为 2.1012651958438786。

研究问题是：不增加训练目标数、不修改模型结构时，对同一训练轨迹的后半段参数做 EMA，能否比最后一步原始权重得到更低的验证 BPB？机制可有负结果；不会把未获得支持的改进写成既定结论。

2. 观察、假设与 EMA 方法

基线在第 300、600、900、1,200 步的验证 BPB 分别为 2.331084、2.184163、2.106116、2.071087。四个点持续改善，但每个 300 步区间的改善缩小。记录的训练损失只是每隔 100 步的单个小批次值，不是 100 步平均；小幅反弹不能证明优化不稳定。这些证据不足以认定过拟合，也不足以认定完全收敛。

待检验假设：平均一段训练过程的参数，可能减少最后一步权重的偶然波动。竞争假设：当模型仍在改善时，较早、较差的参数会拖慢平均权重的进步，反而增加验证 BPB。这两种解释均在读取 EMA 结果之前提出。

预先固定 $\text{decay} = 0.99$ ， $\text{start} = 600$ 。设 w_t 为第 t 次优化器更新后的原始状态， m_t 为平均状态：第 600 步先令 $m_{600} = w_{600}$ ；随后每步令 $m_t = 0.99 \times m_{(t-1)} + 0.01 \times w_t$ 。第 601 至 1,200 步共进行 600 次平均更新。权重贡献的半衰期约为 68.97 次更新；初始化权重的剩余系数为 0.99^{600} ，约 0.002405。

ema.py 独立克隆模型 state_dict。浮点状态按公式平均，整数状态直接复制；导出的状态也是独立副本。每次平均发生在 optimizer.step() 之后，不修改原始权重、优化器或随机采样。最终建立独立模型载入平均权重并验证，保存为普通 PyTorch 检查点。推理只用一套权重，既没有模型集成，也没有测试时训练或检索库。

实现由 18 项测试覆盖：原有 5 项契约检查；EMA 载入后的同等检查；数值公式、整数 buffer、状态独立性、初始化时点、参数边界、检查点往返加载与绑定权重；以及真实小 GPT 在开关 EMA 下原始训练轨迹逐张量一致。新测试先失败，再在实现后通过。完整 seed 17 对照进一步确认原始权重的全部 53 个状态张量与初始基线逐位相等。

3. 同预算实验、消融与结果

B0 是原始完整基线。E0/E1 是同一次 seed 17 训练的原始/平均权重；R0/R1 是预先确定的 seed 23 复核。所有模型结构、优化器、训练步数、batch size 与训练目标数相同。E0 与 E1 的唯一区别是评估时采用哪套权重，因此这一对同时提供同预算对照与关键机制消融；R0/R1 同理。没有继续搜索第二个 decay、不同结构或更长训练预算。

编号 / 权重	seed	累计训练目标	验证 BPB
B0 / raw	17	9,830,400	2.071087433
E0 / raw	17	9,830,400	2.071087433
E1 / ema	17	9,830,400	2.075051428
R0 / raw	23	9,830,400	2.076011404
R1 / ema	23	9,830,400	2.079743500

EMA 减去原始权重的验证 BPB：seed 17 为 +0.003963995，seed 23 为 +0.003732096。正值表示 EMA 更差。两次配对均显示本设置下没有改善，因此本文没有证据支持 EMA 提升预测质量。消融说明差异来自导出的平均状态，而不是增加训练目标数；跨种子比较不能替代同轨迹配对。

按最低验证 BPB 选择 B0 (seed 17, raw 权重)，并在完全相同数值时保留列表中先出现的基线。最终完整测试 BPB 为 2.1012651958438786。B0 的已测测试 BPB 为 2.1012651958438786；其余候选没有用测试分数筛选。最终提交的模型与已实现的 EMA 候选明确区分，不把基线结构或未经证实的平均机制宣称为创新成果。

结果与“平均权重滞后于仍在进步的原始权重”这一解释一致，但没有直接测量参数轨迹的几何性质，不能把它当作已证实的因果机制。仅两个种子和一个 decay，不足以断言 EMA 对其他训练长度、启动时点或任务无效；也未进行统计显著性检验。

4. 资源约束与训练搜索成本

硬件为 Apple M5 (10 核)、16 GiB RAM、macOS 27.0 arm64。Python 3.12.14、PyTorch 2.7.1、NumPy 2.5.3、tokenizers 0.21.4；训练和排名评估均使用 CPU、4 线程、FP32。资源单位中 GiB = 2^{30} 字节，MiB = 2^{20} 字节；EXPERIMENTS.csv 的 peak_ram_gb 是十进制 GB。

冻结后按“基线、最终模型”顺序交错运行 3 轮完整测试。下表计时仅为固定 scorer 的评分阶段，不含 Python 启动、检查点加载和分词；整个进程的墙钟时间另保存在 RESOURCE_RESULTS.json。背景负载和热状态没有硬件级锁定，故报告全部观测与中位数。

重复	基线评分 / 秒	最终评分 / 秒
1	5.762131	6.358576
2	5.657420	6.196672
3	6.275505	6.441884

约束	实测值	上限
最终 / 基线评分中位数	1.1035 倍	5 倍
最终评估进程最大峰值 RSS	1.4535 GiB	4 GiB
最小必需代码、数据、最终权重	17.0661 MiB	64 MiB
保守合计：源码、数据、所有附带模型	33.7677 MiB	64 MiB

内存由 macOS /usr/bin/time -l 测量整个进程，原始输出保留；CPU 的 GPU 显存字段为 0，不用它替代 RAM。资产清单按解压后字节数计数，包含额外对照权重，不以 zip 大小代替；Python 与已安装依赖环境单列，不计为模型资产。全部三项预算均满足。

完整基线、seed 17 配对、seed 23 配对的训练时间分别为 334.006、213.185、237.853 秒。训练时间差不是 EMA 加速的证据：这些运行不处于严格受控的相同负载条件，EMA 本身还增加状态存储和逐步平均运算。

5. 证据边界、失败记录与可复现性

共完成 3 次完整训练与 2 次 10 步安装/EMA smoke，合计 29,655,040 个训练目标，训练时间合计 790.897 秒。每对原始/EMA 导出共享一次训练，搜索总成本只计一次；但每个检查点仍继承全部 9,830,400 个训练目标，不能声称 EMA 权重没有训练成本。

另有一次同配方 seed 17 运行以退出码 120 中止，最后日志为第 200 步、训练时间 68.479 秒，没有 traceback 或检查点。排查时磁盘空间充足，进程已经退出；具体根因与最终完成步数无法确定。保持代码、种子与配方不变，以无缓冲输出和 fault handler 在新目录重试后完成。失败运行未用于模型选择，也没有删除其成本记录。

包含中止运行后，总训练目标数可确认在 31,293,440 至 39,485,440 之间；总训练时间至少 859.377 秒，无法诚实给出精确总数。总计不包含小规模合成单元测试的运行成本；它们不参与模型选择，也不提供提交权重。所有运行、种子、随机初始化关系与不确定部分均在 SEARCH_COSTS.json 和 EXPERIMENTS.csv 中披露。

选择与冻结记录分别为 SELECTION.json 和 FROZEN_FINAL.json；冻结时间为 2026-09-28T22:53:27.413304+08:00。冻结对象包括权重、配置、推理代码及依赖版本；之后对报告和说明文字的编辑不改变预测器。固定 common.py、evaluate.py、model.py、配置及数据哈希与原始包核对一致。评分器的数据加载器会读取并校验全部 split，但开发训练只用 train 做梯度更新，只用 validation 比较候选；禁止以测试结果调参。

最终完整测试包含 428,405 个目标、1,292,013 UTF-8 字节与 1,674 个窗口。三次最终评分一致。交付还要求在独立目录仅使用发布代码与模型包进行直接评估；该复现的原始输出及验证摘要位于 submission/evidence/，不通过重新训练补足资产。

6. 复现入口、来源与 AI 披露

从课程最终提交记录的不可变代码链接获取仓库，在 MP1_student_starter/code 中按

`./REPRODUCE.md` 安装 Python 3.12 和锁定版本的依赖。把配套 `model-bundle.zip` 解压到 `models` 后，运行：`python evaluate.py --checkpoint models/final.pt --device cpu --precision fp32 --threads 4 --split test`。预期 BPB 为 2.1012651958438786；同机当前环境已验证，跨平台浮点计算可能带来细小差异，不能仅凭微小差异断言违规。

配对训练命令、baseline.pt 计时命令、两个种子的 checkpoint 名称与逐文件 SHA-256 均见 `REPRODUCE.md`、`ASSET_MANIFEST.csv` 及模型包 `MANIFEST.json`。无需重新训练即可评分。报告 PDF 共不超过 10 页，包括本页参考来源；中文字体随生成的 PDF 嵌入。

复用声明：GPT 结构、原始优化器配方、tokenizer、数据加载器、固定 evaluator 和最初 5 项契约测试来自课程 starter。EMA 是已有的参数平均方法，本作业贡献是独立状态实现、正确性检查、配对实验和负结果分析，不主张提出新算法。

实质性 AI 帮助：OpenAI Codex 协助制定计划、编写 EMA 及测试、执行和核查实验、解释结果、撰写和排版报告、制作复现说明及打包发布。仓库 README 同样披露。学生仍需理解并能说明所交代码；本报告不虚构学生已完成口头答辩或亲自逐行实现。

参考来源：[1] DASE7506，MP1 supplied GUIDE.md 与 code/README.md（本仓库保留原始任务规范与技术规则）。[2] PyTorch 2.7 文档，`torch.optim.swa_utils.AveragedModel` 与 `get_ema_avg_fn`：参数指数移动平均的定义，<https://docs.pytorch.org/docs/2.7/optim.html>。本实现未调用 `AveragedModel`，依据同一标准算式独立维护状态。[3] Merity, Xiong, Bradbury and Socher，Pointer Sentinel Mixture Models，2016，<https://arxiv.org/abs/1609.07843>。WikiText-2 文本来自 Wikipedia contributors；数据分发声明保留 CC BY-SA 3.0 与 GNU FDL，详见 code/README.md。